Министерство науки и высшего образования Российской Федерации Федеральное государственное автономное образовательное учреждение высшего образования

# УРАЛЬСКИЙ ФЕДЕРАЛЬНЫЙ УНИВЕРСИТЕТ ИМЕНИ ПЕРВОГО ПРЕЗИДЕНТА РОССИИ Б.Н. ЕЛЬЦИНА

(УрФУ имени первого Президента России Б.Н. Ельцина) Институт радиоэлектроники и информационных технологий — РТФ

# ОТЧЁТ

# по лабораторной работе №2

по дисциплине «Методы и инструменты анализа больших данных»

Преподаватель	(дата)	(подпись)	С.Г. Мирвода
Студент	(ната)		А.М. Белоусов
Студент	(дата) ———————————————————————————————————	(подпись)  (подпись)	А.В. Жиденко

Группа: РИМ-201211

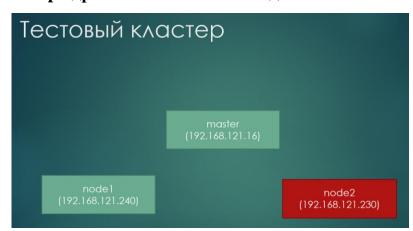
**Цель работы:** знакомство с распределённой файловой системой HDFS.

# Задание 0

Задача: подготовить полигон.

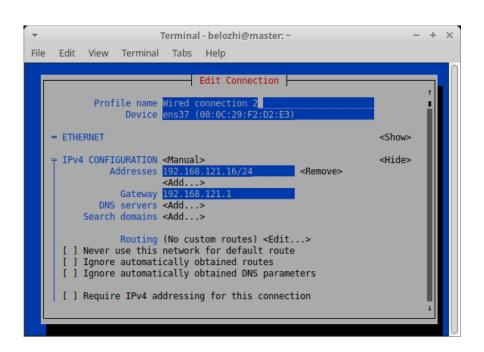
1. Установить и настроить кластер HDFS согласно инструкции Cluster и примеру

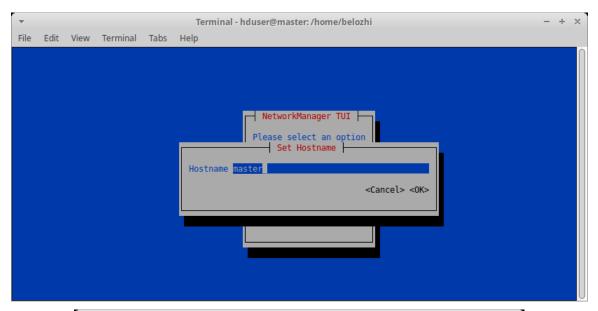
# Настройка ір адреса согласно схеме задания



Настроим имя и ip-адрес BM Master с помощью утилиты nmtui.

### **Nmtui**





```
Terminal - belozhi@master: ~
       Edit View Terminal Tabs Help
su: user hadoop does not exist
belozhi@master:~$ nmtui
belozhi@master:~$ ip addr
1: lo: <LOOPBACK,UP,LOWER_UP> mtu 65536 qdisc noqueue state UNKNOWN group defaul
    link/loopback 00:00:00:00:00:00 brd 00:00:00:00:00:00
    inet 127.0.0.1/8 scope host lo
  valid_lft forever preferred_lft forever
inet6 ::1/128 scope host
valid_lft forever preferred_lft forever
2: ens33: <BROADCAST,MULTICAST,UP,LOWER_UP> mtu 1500 qdisc fq_codel state UP gro
up default qlen 1000
    link/ether 00:0c:29:f2:d2:d9 brd ff:ff:ff:ff:ff
    altname enp2s1
    inet 192.168.128.128/24 brd 192.168.128.255 scope global dynamic noprefixrou
valid_lft 1338sec preferred_lft 1338sec
3: ens37: <BROADCAST,MULTICAST,UP,LOWER_UP> mtu 1500 qdisc fq_codel state UP gro
up default qlen 1000
    link/ether 00:0c:29:f2:d2:e3 brd ff:ff:ff:ff:ff
    altname enp2s5
    inet 192.168.121.16/24 brd 192.168.121.255 scope global noprefixroute ens37
        valid_ltt forever preferred_lft forever
```

#### Установка ssh

sudo apt-get update && sudo apt-get upgrade sudo apt-get install ssh

### Установка Java

\$ sudo apt-get install openjdk-8-jdk

# Создание отдельной учетной записи для запуска Hadoop

sudo addgroup hadoop sudo adduser --ingroup hadoop hduser sudo usermod -aG sudo hduser

## Редактирование файла /etc/hosts

```
Terminal - belozhi@master: ~
                                                                          - + ×
 File Edit View Terminal Tabs Help
 GNU nano 4.8
                                     /etc/hosts
127.0.0.1
                localhost
127.0.1.1
               ubuntu
::1 ip6-localhost ip6-loopback
fe00::0 ip6-localnet
ff00::0 ip6-mcastprefix
ff02::1 ip6-allnodes
ff02::2 ip6-allrouters
192.168.121.16 master
192.168.121.240 node1
192.168.121.230 node2
```

## Получение SSH ключей

```
Terminal - hduser@master: ~
 File
      Edit View
                  Terminal Tabs
                                  Help
hduser@master:/home/belozhi$ ssh-keygen -t rsa
Generating public/private rsa key pair.
Enter file in which to save the key (/home/hduser/.ssh/id_rsa):
Enter passphrase (empty for no passphrase):
Enter same passphrase again:
Your identification has been saved in /home/hduser/.ssh/id rsa
Your public key has been saved in /home/hduser/.ssh/id_rsa.pub
The key fingerprint is:
SHA256:fWSbWGR33BTj7kDGX42btdk+GHzkj0GNckf3BIjKuXQ hduser@master
The key's randomart image is:
+---[RSA 3072]----+
           .0.0==
        =.E==0%=B
        .Soo.+0o@o
        . .o B.
 ----[SHA256]----+
hduser@master:/home/belozhi$ cat ~/.ssh/id_rsa.pub >> ~/.ssh/authorized_keys
hduser@master:/home/belozhi$ chmod 0600 ~/.ssh/authorized keys
hduser@master:/home/belozhi$ ssh localhost
Welcome to Ubuntu 20.04.3 LTS (GNU/Linux 5.11.0-41-generic x86 64)
 * Documentation: https://help.ubuntu.com
  Management:
                  https://landscape.canonical.com
 * Support:
                  https://ubuntu.com/advantage
3 updates can be applied immediately.
```

## Проверка подключения по ssh (ssh localhost)

```
hduser@master:/home/belozhi$ ssh localhost
Welcome to Ubuntu 20.04.3 LTS (GNU/Linux 5.11.0-41-generic x86_64)

* Documentation: https://help.ubuntu.com

* Management: https://landscape.canonical.com

* Support: https://ubuntu.com/advantage

3 updates can be applied immediately.
To see these additional updates run: apt list --upgradable

Your Hardware Enablement Stack (HWE) is supported until April 2025.
Last login: Sat Dec 11 15:32:39 2021 from 192.168.121.240
```

## Установка Apache Hadoop в Ubuntu 20.04

```
wget https://downloads.apache.org/hadoop/common/hadoop-3.3.0/hadoop-3.3.0.tar.gz
```

```
tar -xvzf hadoop-3.3.0.tar.gz
```

su - hduser

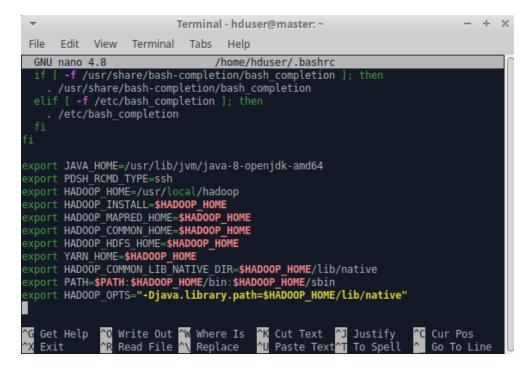
Затем переместим извлеченный каталог в :/usr/local/

sudo mv hadoop-3.3.0 /usr/local/hadoop
sudo mkdir /usr/local/hadoop/logs
chown -R hduser:hadoop /usr/local/hadoop

# **Настройте Apache Hadoop**

Настройка переменных среды в файле ~/.bashrc

### nano ~/.bashrc



#### source ~/.bashrc

Затем нужно определить переменные среды Java, чтобы настроить параметры проекта, связанные с YARN, HDFS, MapReduce и Hadoop:hadoopenv.sh

```
sudo nano $HADOOP_HOME/etc/hadoop/hadoop-env.sh
export JAVA_HOME=/usr/lib/jvm/java-8-openjdk-amd64
```

export HADOOP\_CLASSPATH+=" \$HADOOP\_HOME/lib/\*.jar"

```
Terminal - hduser@master: ~
File
     Edit View
                  Terminal Tabs Help
                       /usr/local/hadoop/etc/hadoop/hadoop-env.sh
GNU nano 4.8
 export HDFS NAMENODE USER=hdfs
This will replace the hadoop.id.str Java property in secure mode.
export HADOOP_REGISTRYDNS_SECURE_EXTRA_OPTS="-jvm server"
 export JAVA_HOME=/usr/lib/jvm/java-8-openjdk-amd64
export HADOOP_CLASSPATH+=" $HADOOP_HOME/lib/*.jar"
             ^O Write Out <sup>^W</sup> Where Is
                                           ^K Cut Text ^J Justify
                                                                         ^C Cur Pos
  Get Help
                 Read File
                                Replace
```

## Проверка версии Hadoop

# hadoop version

```
hduser@master:~$ hadoop version
Hadoop 3.3.0
Source code repository https://gitbox.apache.org/repos/asf/hadoop.git -r aa96f18
71bfd858f9bac59cf2a81ec470da649af
Compiled by brahma on 2020-07-06T18:44Z
Compiled with protoc 3.7.1
From source with checksum 5dc29b802d6ccd77b262ef9d04d19c4
This command was run using /usr/local/hadoop/share/hadoop/common/hadoop-common-3.3.0.jar
```

## Настройка файлов

# Настроить файл core-site.xml

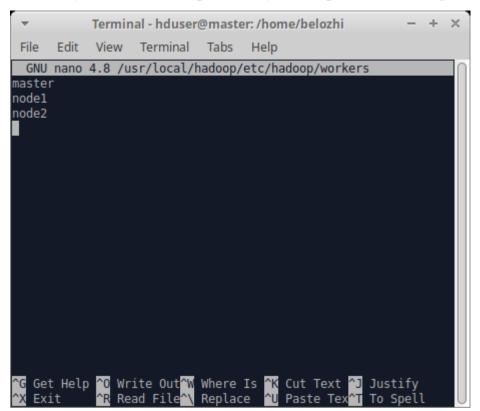
## Настроить файл hdfs-site.xml

```
Terminal - hduser@master: ~
File
     Edit View
                 Terminal Tabs Help
GNU nano 4.8
                    /usr/local/hadoop/etc/hadoop/hdfs-site.xml
                      <name>dfs.replication</name>
                      <value>3</value>
                      <name>dfs.namenode.name.dir</name>
                      <value>file:/usr/local/hadoop/tmp/hdfs/namenode</value>
                      <name>dfs.datanode.data.dir</name>
                      <value>file:/usr/local/hadoop/tmp/hdfs/datanode</value>
            ^O Write Out ^W Where Is
                                       ^K Cut Text
                                                                   Cur Pos
 Get Help
                                                       Justify
               Read File
                            Replace
                                          Paste Text<sup>^</sup>T
                                                       To Spell
```

# Настроить файл mapred-site.xml

### Настроить файл yarn-site.xml

Добавим на узле master все рабочие узлы в файл etc/hadoop/workers.



# Форматирование HDFS NameNode

su - hduser

hdfs namenode -format

# Запуск кластера Hadoop

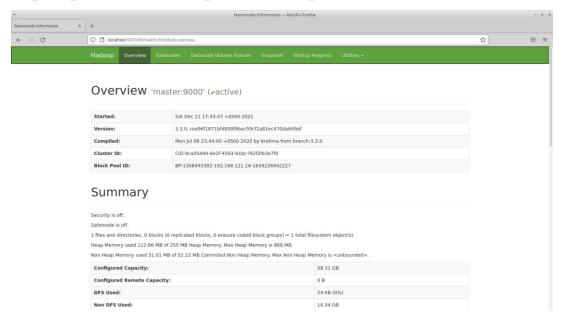
start-dfs.sh

```
hduser@master:~$ start-dfs.sh
Starting namenodes on [master]
Starting datanodes
Starting secondary namenodes [master]
```

### start-yarn.sh

hduser@master:~\$ start-yarn.sh Starting resourcemanager Starting nodemanagers

# Проверка доступа к Apache Hadoop



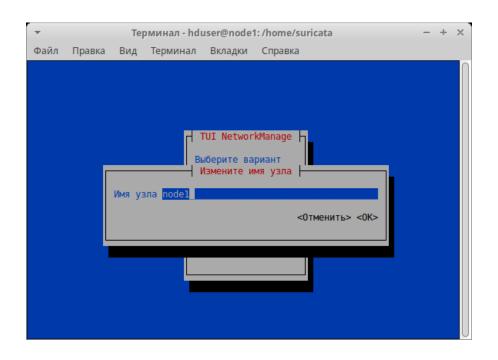
# Задание 1

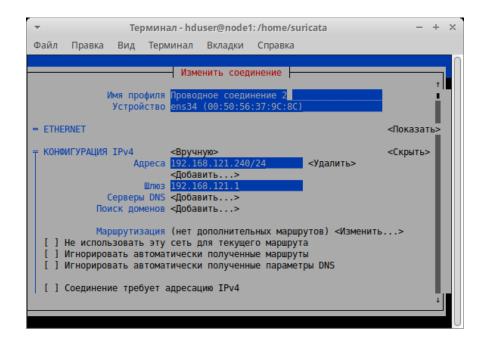
Задача: познакомиться с процессом добавления новых узлов в существующий кластер.

1. Воспользовавшись знаниями из Задания 0 и схемой кластера из презентации (Лабораторная №2), установите и настройте DataNode на узлы кластера node1 и node2.

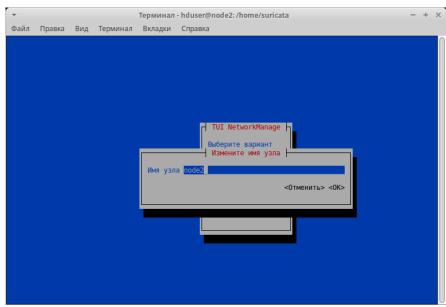
Настройка сетевых имён и ір-адресов на BM node1 и node2.

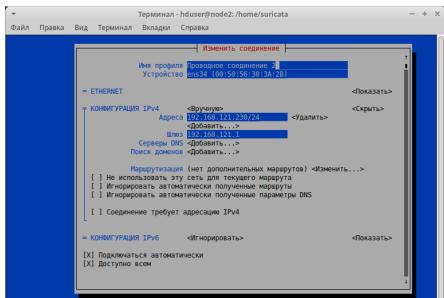
# node1





# node2





Далее аналогичным образом (как в в Задании 0) выполняется:

- Настройка учетной записи hduser
- Получение SSH ключей
- Установка и настройка Наdоор

Копируем ключи SSH на подчиненные машины:

hduser@master: ~\$ ssh-copy-id -i \$HOME/.ssh/id\_rsa.pub hduser@node1 и на вторую:

hduser@master: ~\$ ssh-copy-id -i \$HOME/.ssh/id\_rsa.pub hduser@ node2

Последний шаг настройки - удаление старых каталогов HDFS.

Для этого на мастере и подчиненных узлах нужно удалить каталоги /usr/local/hadoop/hadoop\_tmp/:

sudo rm -rf /usr/local/hadoop/hadoop\_tmp/

Далее на **мастере** создать каталоги namenode и datanode, так как мастермашина у нас одновременно мастер и подчиненная.

Команды:

sudo mkdir -p /usr/local/hadoop/hadoop\_tmp/hdfs/namenode sudo mkdir -p /usr/local/hadoop/hadoop\_tmp/hdfs/datanode

Затем назначить владельцем каталога пользователя hduser группы hadooop:

sudo chown hduser:hadoop -R /usr/local/hadoop/hadoop\_tmp/

На подчиненных машинах сделать тоже самое, но создать только каталог datanode:

sudo mkdir -p /usr/local/hadoop/hadoop\_tmp/hdfs/datanode
sudo chown hduser:hadoop -R /usr/local/hadoop/hadoop\_tmp/

Теперь все готово, отформатируем файловую систему, выполнив команду на Мастере:

hdfs namenode -format

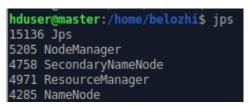
Если нет ошибок, запустим hdfs и yarn с помощью скрипта из первой части, либо командами:

## start-dfs.sh

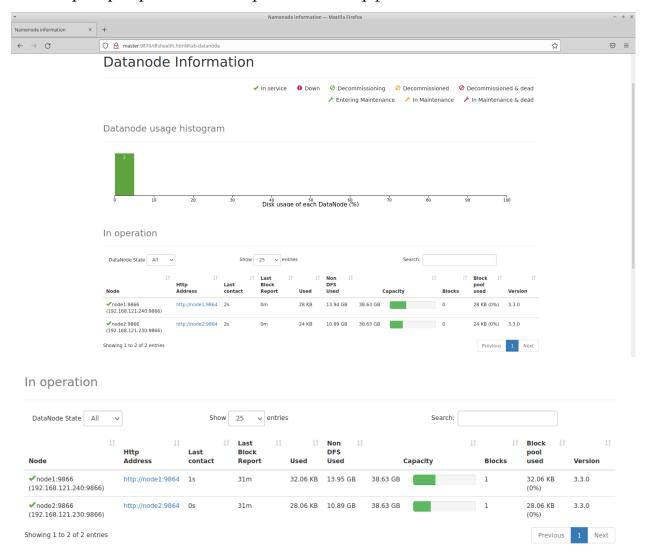
#### start-yarn.sh

```
hduser@master:/home/belozhi$ start-dfs.sh
Starting namenodes on [master]
Starting datanodes
Starting secondary namenodes [master]
hduser@master:/home/belozhi$ start-yarn.sh
Starting resourcemanager
Starting nodemanagers
node2: ERROR: Cannot set priority of nodemanager process 2023
```

С помощью команды jps можно посмотреть запущенные java-процессы на мастере.



Проверка работы кластера в web-интерфейсе.





#### DataNode on node1:9866

Cluster ID:	CID-5ba5b554-c819-470b-b7ec-4c6734423567
Version:	3.3.0, raa96f1871bfd858f9bac59cf2a81ec470da649af

### **Block Pools**

Namenode	Block Pool ID	Actor	Last	Last Block	Last Block Report Size (Max
Address		State	Heartbeat	Report	Size)
master:9000	BP-939744533-192.168.121.16-1639248653348	RUNNING	0s	9 minutes	0 B (128 MB)

### Volume Information

Directory	StorageType	Capacity Used	Capacity Left	Capacity Reserved	Reserved Space for Replicas	Blocks
/usr/local/hadoop/tmp/hdfs/datanode	DISK	28 KB	22.7 GB	0 B	0 B	0

Hadoop, 2020.



### DataNode on node2:9866

Cluster ID:	CID-5ba5b554-c819-470b-b7ec-4c6734423567
Version:	3.3.0, raa96f1871bfd858f9bac59cf2a81ec470da649af

#### **Block Pools**

Namenode	Block Pool ID	Actor	Last	Last Block	Last Block Report Size (Max
Address		State	Heartbeat	Report	Size)
master:9000	BP-939744533-192.168.121.16-1639248653348	RUNNING	0s	9 minutes	0 B (128 MB)

#### Volume Information

Directory	StorageType	Capacity Used	Capacity Left	Capacity Reserved	Reserved Space for Replicas	Blocks
/usr/local/hadoop/tmp/hdfs/datanode	DISK	24 KB	25.75 GB	0 B	0 B	0

Hadoop, 2020.

2. Подключитесь к NameNode с помощью ssh и выполните команду hdfs dfsadmin -report в отчёте вы должны увидеть число узлов (Live datanodes) и свой свежедобавленный узел.

```
hduser@master:/home/belozhi$ ssh node2
Welcome to Ubuntu 20.04.3 LTS (GNU/Linux 5.11.0-41-generic x86_64)

* Documentation: https://help.ubuntu.com

* Management: https://landscape.canonical.com

* Support: https://ubuntu.com/advantage

17 updates can be applied immediately.
Чтобы просмотреть дополнительные обновления выполните: apt list --upgradable

Your Hardware Enablement Stack (HWE) is supported until April 2025.
Last login: Sat Dec 11 23:58:01 2021 from 192.168.121.16
```

```
hduser@node2:~$ hdfs dfsadmin -report
Configured Capacity: 82951274496 (77.25 GB)
Present Capacity: 52018753536 (48.45 GB)
DFS Remaining: 52018700288 (48.45 GB)
DFS Used: 53248 (52 KB)
DFS Used%: 0.00%
Replicated Blocks:
        Under replicated blocks: 0
        Blocks with corrupt replicas: 0
        Missing blocks: 0
        Missing blocks (with replication factor 1): 0
        Low redundancy blocks with highest priority to recover: 0
        Pending deletion blocks: 0
Erasure Coded Block Groups:
        Low redundancy block groups: 0
        Block groups with corrupt internal blocks: 0
        Missing block groups: 0
        Low redundancy blocks with highest priority to recover: 0
        Pending deletion blocks: 0
```

```
Live datanodes (2):
Name: 192.168.121.230:9866 (node2)
Hostname: node2
Decommission Status : Normal
Configured Capacity: 41475637248 (38.63 GB)
DFS Used: 24576 (24 KB)
Non DFS Used: 11692052480 (10.89 GB)
DFS Remaining: 27646300160 (25.75 GB)
DFS Used%: 0.00%
DFS Remaining%: 66.66%
Configured Cache Capacity: 0 (0 B)
Cache Used: 0 (0 B)
Cache Remaining: 0 (0 B)
Cache Used%: 100.00%
Cache Remaining%: 0.00%
Xceivers: 1
Last contact: Sun Dec 12 00:06:38 YEKT 2021
Last Block Report: Sun Dec 12 00:03:20 YEKT 2021
Num of Blocks: 0
```

```
Name: 192.168.121.240:9866 (node1)
Hostname: nodel
Decommission Status : Normal
Configured Capacity: 41475637248 (38.63 GB)
DFS Used: 28672 (28 KB)
Non DFS Used: 14965948416 (13.94 GB)
DFS Remaining: 24372400128 (22.70 GB)
DFS Used%: 0.00%
DFS Remaining%: 58.76%
Configured Cache Capacity: 0 (0 B)
Cache Used: 0 (0 B)
Cache Remaining: 0 (0 B)
Cache Used%: 100.00%
Cache Remaining%: 0.00%
Xceivers: 1
Last contact: Sun Dec 12 00:06:37 YEKT 2021
Last Block Report: Sun Dec 12 00:03:19 YEKT 2021
Num of Blocks: 0
```

# Задание 2

Задача: работа с HDFS с помощью консольных утилит.

- 1. Разделитесь на команды и с помощью утилиты hadoop создайте в кластере:
  - 1.1 Папку с идентификатором своей команды

```
hduser@node2:~$ hadoop fs -mkdir hdfs://master:9000/Belousov_Zhidenko
mkdir: `hdfs://master:9000/Belousov Zhidenko': File exists
```

```
hduser@node2:~$ hadoop fs -ls /
Found 1 items
drwxr-xr-x - hduser supergroup 0 2021-12-12 00:17 /Belousov_Zhidenko
```

1.2 Внутрь папки положите файл с фамилиями участников команды

```
hduser@node2:~$ hadoop fs -ls /
Found 1 items
drwxr-xr-x - hduser supergroup 0 2021-12-12 00:28 /Belousov_Zhidenko
hduser@node2:~$ hadoop fs -ls /Belousov_Zhidenko
Found 1 items
-rw-r--r-- 3 hduser supergroup 52 2021-12-12 00:28 /Belousov_Zhidenko/BeloZhi.txt
```

```
hduser@node2:~$ hadoop fs -cat /Belousov_Zhidenko/BeloZhi.txt
1. Belousov Andrey
2. Zhidenko Alexander
RIM-201211
```

Посмотреть файлы в каталоге Hadoop можно также через webинтерфейс.

